



**Universidade Federal de Uberlândia
Faculdade de Matemática**

Bacharelado em Estatística

**Previsão de Comportamento de Compra de
Clientes em E-commerce: Aplicação de
Modelos Estatísticos de Sobrevivência**

João Marcos de Souza Matos

Uberlândia-MG

2025/1

João Marcos de Souza Matos

Previsão de Comportamento de Compra de Clientes em E-commerce: Aplicação de Modelos Estatísticos de Sobrevivência

Projeto de Trabalho apresentado à Coordenação do Curso de Graduação em Estatística, da Faculdade de Matemática, da Universidade Federal de Uberlândia como requisito necessário para aprovação na disciplina de Estatística Aplicada.

Orientador: José Waldemar da Silva

Uberlândia-MG
2025/1



**Universidade Federal de Uberlândia
Faculdade de Matemática**

Coordenação do Curso de Bacharelado em Estatística

Uberlândia, ____ de _____ de 20____

João Marcos de Souza Matos

José Waldemar da Silva

**Uberlândia-MG
2025/1**

SUMÁRIO

1	Introdução	2
2	Justificativa	4
3	Objetivos	5
4	Metodologia	6
5	Resultados esperados	8
6	Cronograma de atividades	9

1 INTRODUÇÃO

A análise de comportamento de compra dos consumidores em plataformas de e-commerce tem se tornado uma área central de pesquisa devido à crescente competitividade no mercado digital e à importância de entender as preferências dos clientes para melhorar a experiência de compra e maximizar a rentabilidade. O comportamento do cliente online, especialmente no que diz respeito ao tempo e à frequência com que ele realiza compras, pode fornecer insights valiosos sobre a sua lealdade e intenção de compra. No entanto, prever com precisão quando um cliente fará uma compra ou quando ele se tornará inativo representa um desafio significativo para os profissionais da estatística.

O uso de modelos estatísticos ou de modelos treinados a partir de algoritmos de aprendizado de máquina podem ser úteis para prever o comportamento o que contribui para que as empresas, através de seus gestores, tomem decisões mais acertivas. Isso pode direcionar suas estratégias de vendas e marketing. A possibilidade de identificar padrões e comportamentos de clientes antes que ocorra uma compra ou um abandono pode ser a chave para otimizar campanhas de marketing e aumentar a retenção de clientes. Além disso, a compreensão dos métodos de análise de sobrevivência, em especial via aprendizado de máquina, para tratar o tempo de espera até a ocorrência de um evento, como a compra de um produto, de maneira eficaz e incorporando censura e variáveis explicativas contribui grandemente para a formação profissional do estatístico ou analista de dados.

A questão central deste estudo é como modelar o tempo até a próxima compra com base no comportamento ou características do cliente, utilizando dados de um conjunto e-commerce. Além disso, como pode ser previsto a probabilidade de um cliente não comprar novamente (abandono) dentro de um intervalo de tempo é outra questão interessante. Esses questionamentos são relevantes pois suas respostas podem contribuir para o entendimento da dinâmica de compra, prever a rotatividade de clientes e otimizar a alocação de recursos de marketing.

O linguagem de programação Python [?] é uma excelente escolha para implementar essa análise, pois oferece bibliotecas especializadas para análise de sobrevivência, como a *lifelines*, que contém funções tanto para o ajuste de modelos de Cox quanto para o cálculo da curva de Kaplan-Meier. Além disso, o Python é uma plataforma amplamente utilizada em ciência de dados, proporcionando uma grande quantidade de recursos e documentação, o que facilita o aprendizado e a implementação de análises complexas.

Os dados sobre os quais será aplicada a metodologia vêm do “E-commerce Customer Behavior and Purchase Dataset”, um conjunto de dados sintético gerado pela biblioteca Faker do Python, disponibilizado na plataforma Kaggle [?], que simula o comportamento de clientes em um e-commerce. Este conjunto contém variáveis como tempo de navegação, frequência de compras, histórico de interações com a plataforma e outros dados importantes para modelar a probabilidade de um cliente realizar ou não uma compra em determinado período de tempo.

Portanto, este estudo visa explorar a aplicação da análise de sobrevivência via aprendizado de máquina, para prever comportamentos de compra em e-commerce, usando o Python como

ferramenta de análise e o conjunto de dados mencionado para fornecer insights valiosos sobre os fatores que influenciam a decisão de compra dos consumidores online. A capacidade de prever esses comportamentos pode não só melhorar a experiência do cliente, mas também aumentar a eficiência das campanhas de marketing e da gestão de relacionamento com o cliente, resultando em benefícios para os negócios.

2 JUSTIFICATIVA

A abordagem do problema de prever o comportamento de compra dos consumidores em e-commerce se justifica pela crescente importância de compreender as dinâmicas de consumo no contexto digital. O mercado online é altamente competitivo e dinâmico, e empresas que conseguem antecipar as intenções de compra de seus clientes têm uma vantagem significativa. A capacidade de prever quando um cliente realizará uma nova compra ou quando pode abandonar a plataforma permite que as empresas ajustem suas estratégias de marketing de forma mais eficiente, direcionando campanhas personalizadas, otimizando o estoque e melhorando a experiência do cliente. Além disso, prever a rotatividade de clientes (churn) é crucial para reduzir os custos com aquisição de novos consumidores e aumentar a retenção dos clientes existentes, que são fontes mais lucrativas para os negócios.

A utilização da análise de sobrevivência é particularmente adequada para esse tipo de estudo, pois permite modelar o tempo até a ocorrência de um evento específico, como a realização de uma compra ou o abandono de um cliente. Modelos como o de Cox são eficazes para identificar os fatores que influenciam o comportamento do consumidor ao longo do tempo, permitindo a inclusão de variáveis como histórico de compras, frequência de visitas e características demográficas. Além disso, essa abordagem leva em consideração a censura, ou seja, a situação em que o evento de interesse (compra ou abandono) não ocorre dentro do período de observação.

A abordagem do tempo de vida via algoritmos de árvore de sobrevivência, ou árvore de decisão para dados de sobrevivência e floresta aleatória também para este mesmo tipo de dados é uma abordagem possível e promissora principalmente atualmente quando os bancos de dados em geral são grandes.

Dessa forma, a análise de sobrevivência não apenas oferece uma metodologia robusta para a previsão de comportamentos de compra, mas também permite uma compreensão mais aprofundada dos fatores que influenciam a lealdade e a rotatividade dos clientes. [?]

3 OBJETIVOS

O objetivo principal deste estudo é desenvolver um modelo preditivo utilizando técnicas de análise de sobrevivência para prever o comportamento de compra dos clientes em um ambiente de e-commerce. O foco é modelar o tempo até a próxima compra ou o abandono do cliente, a fim de fornecer insights valiosos para otimização de estratégias de marketing e aumento da retenção de clientes.

Os objetivos específicos para o desenvolvimento do trabalho são:

- Obter e preparar os dados do conjunto “E-commerce Customer Behavior and Purchase Datase”;
- Realizar o pré-processamento dos dados, incluindo a limpeza, transformação e seleção das variáveis relevantes para a análise;
- Aplicar a análise de sobrevivência, utilizando o modelo de Cox e os algoritmos árvore de decisão e floresta aleatória, para identificar os fatores que influenciam o comportamento de compra e o tempo até a próxima compra ou abandono;
- Avaliar a performance do modelo gerado, utilizando métricas adequadas para análise de sobrevivência, como o valor p, a curva de Kaplan-Meier e o risco relativo.
- Interpretar os resultados para oferecer recomendações práticas para as empresas de e-commerce, visando melhorar as estratégias de marketing, aumentar a fidelização e reduzir a rotatividade de clientes.

4 METODOLOGIA

A análise de sobrevivência é uma abordagem estatística amplamente utilizada para estudar o tempo até a ocorrência de um evento de interesse, como morte, falha de um sistema ou recuperação de uma doença, ou ainda, compra realizada por um cliente. No contexto não-paramétrico, essa análise não faz suposições rígidas sobre a distribuição subjacente dos tempos de sobrevivência, sendo particularmente útil em cenários onde tais pressupostos não podem ser validados.

O método Kaplan-Meier é uma técnica não-paramétricas muito comuns. Ele permite a estimativa da função de sobrevivência, que representa a probabilidade de um indivíduo sobreviver além de um determinado tempo. A função é construída com base em intervalos definidos pelos tempos de falha observados, ajustando a probabilidade de sobrevivência em cada etapa pelo número de indivíduos ainda em risco. O Kaplan-Meier é especialmente útil em dados censurados, nos quais informações completas sobre o tempo até o evento não estão disponíveis para todos os indivíduos da amostra (Kaplan & Meier, 1958) [?].

Outro método importante é o teste de log-rank, usado para comparar funções de sobrevivência entre dois ou mais grupos. Esse teste avalia se há diferença significativa entre as curvas de sobrevivência, assumindo que os riscos são proporcionais ao longo do tempo (Mantel, 1966). Ele é amplamente aplicado em estudos clínicos para comparar tratamentos ou condições de saúde.

Os métodos não-paramétricos de análise de sobrevivência possuem vantagens notáveis, incluindo a flexibilidade e a capacidade de lidar com censuras. No entanto, apresentam limitações, como a dificuldade de incorporar múltiplas covariáveis, o que frequentemente exige o uso de modelos semi-paramétricos ou paramétricos, como o modelo de riscos proporcionais de Cox (Cox, 1972) [?].

Recentemente, métodos baseados em aprendizado de máquina, como as árvores de decisão e florestas aleatórias, têm sido aplicados com sucesso para lidar com dados de sobrevivência devido à sua flexibilidade e capacidade de capturar relações não lineares entre variáveis.

Para análise com árvores de decisão, utiliza-se a extensão da metodologia para dados censurados, como a “Survival Tree” baseada no algoritmo CART (Classification and Regression Tree). Este método adapta os critérios de divisão, como o índice de Gini ou a redução da variância, para maximizar a separação em termos de risco entre os nós, utilizando métricas específicas para dados de sobrevivência, como a estatística log-rank ou a redução na discrepância de Kaplan-Meier entre subgrupos (Therneau et al., 1990) [?].

As florestas aleatórias para dados de sobrevivência, conhecidas como Random Survival Forests (RSF), são uma generalização das florestas aleatórias introduzida por Breiman (2001) [?] e posteriormente adaptada para dados de sobrevivência por Ishwaran et al. (2007) [?]. Nesse método, diversas árvores de decisão são construídas a partir de amostras bootstrap dos dados, com divisões realizadas de forma aleatória e baseadas em critérios específicos de sobrevivência. Cada árvore fornece uma estimativa da função de risco cumulativo, e os resultados são

agregados para melhorar a robustez e reduzir o viés.

A validação dos modelos é feita utilizando técnicas como validação cruzada ou separação dos dados em conjuntos de treinamento e teste. Métricas específicas para análise de sobrevivência, como a C-index (índice de concordância), são utilizadas para avaliar o desempenho dos modelos em prever a ordem dos tempos de sobrevivência (Harrell et al., 1982) [?]. Além disso, gráficos de Kaplan-Meier podem ser usados para visualizar os riscos entre os grupos identificados.

As florestas aleatórias apresentam vantagens significativas em relação às árvores de decisão individuais, incluindo maior precisão e estabilidade devido à agregação de múltiplas árvores. Entretanto, ambas as abordagens são sensíveis à escolha de hiperparâmetros, como o número de árvores e o número mínimo de observações por nó terminal, que devem ser ajustados de forma adequada por meio de técnicas de otimização.

As análises serão implementadas no ambiente de programação Python que possui bibliotecas específicas para o tipo de análise prevista neste projeto como, por exemplo, a biblioteca *lifelines*.

5 RESULTADOS ESPERADOS

Ao final deste estudo, espera-se alcançar um modelo preditivo robusto que seja capaz de prever com precisão o comportamento de compra dos clientes em um ambiente de e-commerce, especificamente o tempo até a próxima compra ou o risco de abandono. O produto final será uma análise detalhada dos fatores que influenciam essas decisões de compra, com base em variáveis como frequência de visitas, histórico de compras e características demográficas dos clientes. Com isso, será possível identificar segmentos de clientes com maior probabilidade de realizar compras e aqueles em risco de abandonar a plataforma, permitindo que estratégias de marketing sejam mais eficazmente direcionadas.

Além disso, espera-se que os resultados possam fornecer insights valiosos para empresas de e-commerce, permitindo a otimização de campanhas de marketing, a personalização da experiência do usuário e a redução da rotatividade de clientes. O modelo de análise de sobrevivência aplicado, com ênfase no modelo de Cox, será uma ferramenta útil para que as empresas possam antecipar comportamentos e tomar decisões informadas para aumentar a fidelização e maximizar a rentabilidade.

Porém, algumas limitações precisam ser consideradas. Em primeiro lugar, os dados utilizados são sintéticos e podem não refletir perfeitamente a complexidade e a variabilidade dos comportamentos reais dos clientes em plataformas de e-commerce. Isso pode limitar a generalização dos resultados para outros contextos ou mercados. Além disso, o tempo disponível para a realização da pesquisa pode restringir a profundidade da análise, especialmente em relação à exploração de diferentes técnicas de modelagem ou à inclusão de outras variáveis que poderiam enriquecer o modelo preditivo.

Apesar dessas limitações, espera-se que os resultados obtidos contribuam para o aprimoramento do conhecimento científico na área de previsão de comportamento de clientes em e-commerce, especialmente no que tange à utilização de modelos de análise de sobrevivência em contextos digitais. Os insights gerados também têm o potencial de servir como uma fonte útil de informação para empresas de e-commerce, que poderão aplicar as recomendações para melhorar suas estratégias de marketing e aumentar a retenção de clientes, resultando em uma gestão mais eficiente e assertiva de seus recursos.

6 CRONOGRAMA DE ATIVIDADES

Na Tabela 1 é apresentado o cronograma de atividades a serem desenvolvidas ao longo do semestre.

Tab. 1: Atividade previstas, por mês de execução do projeto.

Atividade	Mês			
	Jun	Jul	Ago	Set
Definição do tema com o orientador	x			
Determinação do objetivo principal	x			
Determinação dos objetivos específicos	x			
Pesquisa bibliográfica	x	x	x	x
Elaboração do Projeto de Trabalho		x		
Familiarização com a linguagem de programação prevista		x	x	x
Aplicação da metodologia		x	x	x
Obtenção e discussão dos resultados		x	x	x
Apresentação do relatório final			x	x