



Universidade Federal de Uberlândia
Faculdade de Matemática

Bacharelado em Estatística

Redes neurais bayesianas na modelagem do desempenho de estudantes

Henrique Garcia Souza

Uberlândia-MG
2024

Henrique Garcia Souza

Redes neurais bayesianas na modelagem do desempenho de estudantes

Relatório Parcial apresentado à Coordenação do
Curso de Graduação em Estatística, da Faculdade
de Matemática, da Universidade Federal de Uber-
lândia como requisito para aprovação na disciplina
de Trabalho de Conclusão de Curso.

Orientador: José Waldemar da Silva

Uberlândia-MG
2024



**Universidade Federal de Uberlândia
Faculdade de Matemática**

Coordenação do Curso de Bacharelado em Estatística

Uberlândia, ____ de _____ de 20____

Henrique Garcia Souza

José Waldemar da Silva

**Uberlândia-MG
2024**

SUMÁRIO

1	Introdução	2
2	Metodologia	3
2.1	Os dados	3
2.2	Árvore de decisão	4
2.3	Floresta aleatória	4
3	Rede neural	5
4	Rede neural Bayesiana	6
5	Resultados	7
5.1	Tratamentos dos dados	7
5.2	Análise de correlação	7
5.3	Análises numéricas e gráficas	8
5.4	Modelos	10
6	Conclusão	11

1 INTRODUÇÃO

Bom desempenho escolar pode ser um divisor de águas na vida de uma pessoa, pode permitir o acesso a uma melhor universidade, pode ser munição para desenvolver ideias novas e além de tudo ajuda a preparar a pessoa para a vida adulta. Com isso em mente, é de fundamental importância identificar fatores que possam determinar ou interferir no desempenho escolar. Modelos construídos a partir destes fatores, via aprendizado de máquina, o que inclui redes neurais bayesianas, podem ser úteis na previsão do desempenho de indivíduos. A dúvida que fica é, como saber se uma pessoa irá bem ou não em seus estudos no colégio.

Uma ferramenta que poderíamos usar para resolver nosso problema seria um modelo de aprendizado de máquina supervisionado como uma regressão linear ou uma árvore de decisão, esses modelos nada mais são do que modelos que permitem o computador a aprender, e aprender é o processo de achar padrões estatísticos ou outros padrões nos dados [?].

Contudo, vamos partir para uma abordagem utilizando redes neurais, as redes neurais são compostas por camadas de um nó, contendo uma camada de entrada, uma ou mais camadas ocultas e uma camada de saída. Cada nó, ou neurônio artificial, conecta-se a outro e tem um peso e um limite associados [?].

Para realizar este estudo será utilizado uma rede neural bayesiana (RNB) a fim de criar um modelo capaz de prever se um aluno irá bem ou não nas matérias do colégio, tal modelo pode ser capaz de auxiliar a escola ou os pais a agirem previamente com o aluno para reverter os casos de mal desempenho. A RNB assim como uma rede neural comum é uma forte técnica de modelagem, porém, a bayesiana tem como vantagem permitir considerar a distribuição de todas as respostas [?]. Usaremos o software R [?] e o python [?] para o desenvolvimento do estudo.

Os dados para o desenvolvimento desse estudo são fictícios e foram retirados do Kaggle [?], porém apesar de serem fictícios é interessante notar que ele traz apenas variáveis que são de fácil coleta o que permitiria a implementação do modelo na vida real.

2 METODOLOGIA

No desenvolvimento desta pesquisa foram utilizados modelos de machine learning na tentativa de se obter material comparativo entre métodos mais tradicionais de modelagem e uma rede neural bayesiana.

O Conjunto de dados é fictício, mas serve como motivação para futuras pesquisas com dados reais acerca deste tema, de fato o entendimento do que define um bom desempenho escolar é um tema que não deve ser negligenciado por aqueles que visam melhorar a educação como um todo.

2.1 OS DADOS

Os dados foram obtidos a partir do site kaggle[?] e são fictícios, apesar disso ainda são muito úteis para que possamos ter ideias de possíveis análises e abordagens acerca do tema. A base de dados conta com 15 colunas onde uma é um índice, 9 são categóricas e 5 são numéricas, destas 5, 3 são variáveis resposta, scores divididos entre leitura, escrita e matemática.

A tabela 1 a seguir resume sobre o que cada variável significa.

TAB. 1: Descrição das Variáveis

Variável	Descrição
Gender	Gênero do estudante
EthnicGroup	Grupo Étnico do estudante, de A a E
ParentEduc	Nível de escolaridade dos pais
LunchType	Tipo de merenda escolar (padrão ou gratuita/reduzida)
TestPrep	Teste preparatório, completo ou não
ParentMaritalStatus	Status civil dos pais
PracticeSport	Freqüência com que pratica esportes
IsFirstChild	Se é ou não primeiro filho
NrSiblings	Número de irmãos do estudante
TransportMeans	Meio de locomoção para a escola
WklyStudyHours	Horas semanais de estudo, menos de 5 horas; entre 5 e 10 horas; mais de 10 horas
MathScore	Score de matemática
ReadingScore	Score de leitura
WritingScore	Score de escrita

2.2 ÁRVORE DE DECISÃO

O primeiro modelo ajustado para ser usado como comparativo foi uma árvore de decisão, árvores são modelos hierárquicos, isto é, modelos que usam uma série de perguntas para levar a uma decisão, estas perguntas são criadas observando um número grande de outras amostras do mesmo problema[?].

A árvore é formada por nós, ramos e nós folhas, onde cada nó divide a árvore baseado em um atributo do conjunto de dados, cada ramo é a representação dos valores que estão classificados em cada nó e os nós folhas ou final representam o fim da árvore onde os dados estão separados após passarem por todos os nós.




FIG. 1: Exemplo de árvore de decisão

Fonte: [Colaborae](#)

Para decidir qual o melhor ponto de corte de uma variável e o quanto essa variável traz de ganho para separar a informação, usou-se o critério do erro quadrático médio (MSE). O MSE é calculado como a média dos quadrados das diferenças entre os valores previstos e os valores reais. O objetivo do modelo é minimizar o MSE durante o processo de treinamento, o que significa que ele busca encontrar a árvore de decisão que melhor se ajusta aos dados de treinamento, minimizando o erro médio ao prever os valores alvo.

2.3 FLORESTA ALEATÓRIA

Uma floresta aleatória (Random Forest) é um tipo de algoritmo de aprendizado de máquina que é usado tanto para tarefas de classificação quanto para regressão. É uma técnica de conjunto (ensemble) que combina várias árvores de decisão individuais para criar um modelo mais robusto e preciso.

A ideia fundamental por trás da floresta aleatória é criar várias árvores de decisão independentes durante o processo de treinamento. Cada árvore de decisão é treinada em uma amostra aleatória dos dados de treinamento e, durante a construção da árvore, em cada divisão de nó, apenas um subconjunto aleatório das características (variáveis) é considerado para determinar a melhor divisão. Isso introduz aleatoriedade e diversidade no processo de construção das árvores[?].

Após treinar todas as árvores de decisão, a previsão de uma nova instância é feita pela maioria das previsões das árvores individuais no caso de classificação (voto majoritário) ou pela média das previsões no caso de regressão.




FIG. 2: Exemplo de Floresta aleatória

Fonte: [Deniz Gunay](#)

3 REDE NEURAL

A rede neural tem como objetivo tentar simular a maneira como um cérebro humano pensa, criando neurônios e fazendo ligações entre eles, o conceito de rede neural surgiu com o modelo matemático de um neurônio biológico proposto por Warren McCulloch e Walter Pitts em 1943. O modelo, denominado neurônio MCP (McCulloch-Pitts), é descrito por um conjunto de n entradas, as quais são multiplicadas por um determinado peso e, em seguida, os resultados são somados e comparados a um limiar[?].

Atualmente existem diversos modelos de redes neurais, cada um mais adequado para a resolução de um problema específico, a seguir alguns dos principais modelos de redes neurais

- **Feedforward Neural Networks (Redes Neurais de Avanço):** Também conhecidas como redes neurais multicamadas (Multilayer Perceptrons - MLPs), essas redes consistem em uma sequência de camadas de neurônios, onde as conexões entre os neurônios não formam ciclos. Essas redes são usadas para tarefas de classificação, regressão e outras, dependendo da arquitetura específica[?];
- **Convolutional Neural Networks (Redes Neurais Convolucionais - CNNs):** Essas redes são projetadas para processar dados de grade, como imagens. Elas usam camadas de convolução para aprender características espaciais, reduzindo a quantidade de parâmetros e melhorando a eficiência do aprendizado em dados de imagem. As CNNs são amplamente usadas em tarefas de visão computacional, como reconhecimento de imagem, segmentação e detecção de objetos[?];
- **Recurrent Neural Networks (Redes Neurais Recorrentes - RNNs):** Essas redes são projetadas para processar sequências de dados, onde as conexões entre neurônios formam loops, permitindo que a rede mantenha uma memória de estados anteriores. As RNNs são usadas em tarefas como processamento de linguagem natural (NLP), tradução de idiomas, previsão de séries temporais e muito mais[?];

- **Generative Adversarial Networks (Redes Generativas Adversariais - GANs):** Este tipo de rede neural consiste em duas redes neurais, um gerador e um discriminador, que são treinadas simultaneamente em uma competição entre si. As GANs são usadas para gerar dados novos e realistas, como imagens, áudio e texto[?].

Para o presente trabalho, foi aplicada uma rede neural feedforward, por ser mais indicada para lidar com casas de regressão, trabalhou-se com uma rede neural com 2 camadas, sendo a primeira com 3 neurônios com ativação ReLU e a segunda a camada de saída linear

A ativação ReLU (Rectified Linear Unit) é definida como:

$$f(x) = \max(0, x)$$

A principal razão para o uso da função ReLU é a sua simplicidade computacional e eficácia em redes neurais profundas. Algumas das suas características incluem:

- **Não saturação:** A função ReLU não satura para valores positivos de entrada, o que significa que ela não fica presa em uma faixa de valores onde a derivada é zero durante o treinamento, como acontece com funções de ativação como a sigmoide e a tangente hiperbólica. Isso ajuda na prevenção do desaparecimento do gradiente, tornando o treinamento mais rápido e eficiente;
- **Esparsidade de ativação:** A função ReLU induz uma esparsidade nas ativações da rede, o que significa que menos neurônios são ativados, resultando em redes mais eficientes computacionalmente;
- **Facilidade de interpretação:** A função ReLU torna as previsões do modelo mais fáceis de interpretar, pois os valores de saída positivos são diretamente proporcionais às entradas positivas, o que facilita a compreensão do comportamento do modelo.

4 REDE NEURAL BAYESIANA

Os procedimentos tradicionais para determinar os parâmetros das redes neurais vem a partir da aplicação dos princípios estatísticos de máxima verossimilhança. No entanto, essas técnicas podem apresentar diversas limitações. Por contraste, a utilização de métodos estatísticos Bayesianos na estimativa dos parâmetros oferece a vantagem de modelar tais relações com base em distribuições probabilísticas. Isso possibilita a realização de aproximações das funções enquanto se considera a estimativa de suas incertezas.[?]

Nas redes neurais Bayesianas, o objetivo é construir a função de distribuição de probabilidade a posteriori dos parâmetros da rede, com base nos dados disponíveis. Dessa maneira, densidades de probabilidade são construídas em cada ponto do espaço de parâmetros da rede.[?]

A abordagem Bayesiana traz várias características importantes, como:

- o treinamento convencional baseado na minimização de uma função de erro pode ser visto como um caso particular do tratamento Bayesiano geral;
- a abordagem Bayesiana possui de modo natural, uma técnica de regulação de parâmetros pela qual são penalizados os parâmetros que possuem valores altos;
- $\frac{3}{4}$ o método Bayesiano permite que os valores dos coeficientes de regulação sejam selecionados a partir dos dados de treinamento, desta forma não precisa separar um conjunto de dados para a validação cruzada;
- a abordagem Bayesiana permite fazer a comparação de modelos (redes com diferente número de neurônios da camada escondida), usando só os dados de treinamento (princípio de Occam's razor); [?]

5 RESULTADOS

5.1 TRATAMENTOS DOS DADOS

Após a obtenção dos dados, verificou-se que haviam dados faltantes e para trata-los utilizou-se as seguintes técnicas:

- Para as variáveis numéricas os valores ausentes foram preenchidos com a média de cada variável
- Para as variáveis categóricas os valores ausentes foram preenchidos com a moda de cada variável

Após preencher os dados faltantes, verificou-se se haviam dados duplicados, porém nenhuma instância foi identificada.

5.2 ANÁLISE DE CORRELAÇÃO

A Figura 3 apresenta a matriz de correlação das variáveis consideradas neste estudo. Neste gráfico, a escala de cor é usada como auxílio para identificação de pares de variáveis correlacionadas. Quanto mais próximo dos limites -1 e 1 são os valores estimados, mais destacadas são as cores (vermelho ou verde). As cores se tornam neutras nas proximidades do valor zero.




FIG. 3: Matriz de correlação amostral

Fonte: Elaborado pelo Autor, 2024.

A Partir da análise gráfica observou-se que as variáveis são pouquíssimo correlacionadas.

5.3 ANÁLISES NUMÉRICAS E GRÁFICAS

Para os escores de matemática, leitura e escrita foi avaliado a média, o maior valor e o menor valor, a fim de entender o comportamento das variáveis, os resultados estão na tabela 2

TAB. 2: Análises numéricas dos escores

Variável	Menor valor	Média	Maior valor
Escore de matemática	0	66,55	100
Escore de leitura	10	69,	100
Escore de escrita	4	68,41	100

É possível observar que todos os 3 escores possuem uma distribuição parecida, para confirmar esta hipótese construiu-se o histograma das 3 variáveis.

FIG. 4: Histograma do escore de matemática






FIG. 5: Histograma do escore de escrita**FIG. 6:** Histograma do escore de leitura

Assim como a análise numérica indicou, o histograma evidenciou que de fato os escores possuem distribuições muito similares.

5.4 MODELOS

A fim de modelar o conjunto dados para tentar prever o escore de cada aluno, construiu-se uma variável que combinava as 3 respostas (escore de matemática, escore de escrita e escore de leitura) em uma só, a partir da média das 3, criando assim um escore combinado.

A partir disso, aplicaram-se 4 modelos diferentes para tentar prever o escore combinado de cada aluno, árvore de decisão, floresta aleatória, rede neural e rede neural bayesiana.

O primeiro passo para a aplicação dos modelos foi a transformação das variáveis categóricas em variáveis dummies, variáveis numéricas que indicam uma categoria. Após isso separou-se o conjunto de dados em dois, um para treinar o modelo e outro para testar os modelos aplicados.

Foi utilizado também a técnica de validação cruzada para obter as estimativas mais robustas dos modelos.

TAB. 3: Tabela com 4 grandes colunas e 3 subcolunas

Árvore de decisão			
Etapa da validação cruzada 1	MSE	RMSE	MAE
Primeira iteração	298,30	17,27	13,83
Segunda iteração	307,85	17,54	14,11
Terceira iteração	305,05	17,46	14,03
Quarta iteração	301,33	17,35	13,86
Quinta iteração	302,96	17,40	13,99
Média	303.70	17.40	13.96
Floresta aleatória			
Etapa da validação cruzada 1	MSE	RMSE	MAE
Primeira iteração	188,28	13,72	11,03
Segunda iteração	196,71	14,02	11,25
Terceira iteração	196,75	14,02	11,34
Quarta iteração	190,02	13,78	11,12
Quinta iteração	199,19	14,11	11,41
Média	194.59	13.93	11.23
Rede neural			
Etapa da validação cruzada 1	MSE	RMSE	MAE
Primeira iteração	149,15	12,21	9,93
Segunda iteração	154,25	12,41	10,04
Terceira iteração	157,60	12,55	10,18
Quarta iteração	155,91	12,48	10,15
Quinta iteração	159,21	12,61	10,24
Média	155.02	12.45	10.11
Rede neural Tito1999			
Etapa da validação cruzada 1	MSE	RMSE	MAE
Primeira iteração	292,11	17,09	13,78
Segunda iteração	271,87	16,48	13,32
Terceira iteração	260,48	16,13	13,03
Quarta iteração	281,85	16,78	13,58
Quinta iteração	274,54	16,56	13,37
Média	276.37	16.61	13.42

Após a avaliação dos resultados de todos os modelos, foi possível observar que a rede neural tradicional se destacou como melhor opção de modelo, apresentando uma média em todas as métricas avaliadas menor do que em comparação com os outros modelos testados, com um MSE médio de 155.02, RMSE médio de 12.45 e MAE médio de 10.11.

6 CONCLUSÃO

Após a aplicação dos modelos para tentar prever o score de cada aluno, ficou evidenciado que a rede neural seria a melhor escolha para este conjunto de dados, com erros baixos em relação ao real valor dos scores, o estudo evidencia que é viável tentar prever a qualidade no desempenho escolar.

O bom resultado do ajuste serve como munição para encorajar trabalhos futuros que busquem ter acesso a dados reais relacionados a desempenho estudantil. Assim buscando entender se o comportamento de dados reais é similar ao simulado.

O trabalho consegue atingir seu objetivo de estudar o conjunto de dados e aplicar os modelos para entender qual seria a melhor opção para prever o score dos alunos, apesar de se tratarem de dados fictícios, o resultado é muito positivo e chama atenção para opções futuras implementadas na sociedade.