



Universidade Federal de Uberlândia
Instituto de Matemática e Estatística

Bacharelado em Estatística

**PREVISÃO DE COMPORTAMENTO DE
COMPRA DE CLIENTES EM
E-COMMERCE: APLICAÇÃO DE
MODELOS ESTATÍSTICOS DE
SOBREVIVÊNCIA**

João Marcos de Souza Matos

Uberlândia-MG

2025

João Marcos de Souza Matos

**PREVISÃO DE COMPORTAMENTO DE
COMPRA DE CLIENTES EM
E-COMMERCE: APLICAÇÃO DE
MODELOS ESTATÍSTICOS DE
SOBREVIVÊNCIA**

Relatório Parcial apresentado à Coordenação do
Curso de Graduação em Estatística, da Faculdade
de Matemática, da Universidade Federal de Uber-
lândia como requisito para aprovação na disciplina
de Trabalho de Conclusão de Curso.

Orientador: José Waldemar da Silva

**Uberlândia-MG
2025**



**Universidade Federal de Uberlândia
Faculdade de Matemática**

Coordenação do Curso de Bacharelado em Estatística

Uberlândia, ____ de _____ de 20____

João Marcos de Souza Matos

José Waldemar da Silva

**Uberlândia-MG
2025**

SUMÁRIO

Lista de Figuras	2
Lista de Tabelas	3
1 Introdução	4
2 Justificativa	4
3 Objetivos	4
3.1 Objetivos Específicos	4
4 Metodologia	5
4.1 Fonte de Dados e Ferramentas	5
4.2 Tratamento dos Dados	5
4.3 Pré-processamento e Tratamento dos Dados	5
4.4 Engenharia de Atributos para Sobrevivência	6
4.5 Modelagem Estatística	7
4.5.1 Métodos Não-Paramétricos	7
4.5.2 Métodos Semi-Paramétricos	8
4.6 Avaliação dos Modelos	9
5 Resultados	9
5.1 Análise Exploratória de Dados (AED)	9
5.1.1 Estatísticas Descritivas	9
5.1.2 Distribuição das Variáveis Categóricas	10
5.1.3 Análise Bivariada vs. Churn	10
5.2 Análise de Sobrevivência	12
5.2.1 Análise Exploratória das Variáveis de Sobrevivência	12
5.2.2 Análise Não-Paramétrica: Estimador de Kaplan-Meier	13
5.2.3 Análise Semi-Paramétrica: Modelo de Riscos Proporcionais de Cox	15
6 Conclusão	16

LISTA DE FIGURAS

1	Distribuição dos valores da coluna Returns antes do tratamento dos dados ausentes.	6
2	Distribuição dos valores da coluna Returns após a substituição de valores nulos por 0.	7
3	Distribuição das variáveis categóricas: Categoria de Produto, Método de Pagamento, Gênero e Churn.	11
4	Análise bivariada das variáveis em relação ao Churn.	12
5	Análise Bivariada de covariáveis vs. a variável evento	13
6	Análise Bivariada de covariáveis vs. a variável duracao	14
7	Curva de Sobrevivência de Clientes (Estimador de Kaplan-Meier).	14

LISTA DE TABELAS

1	Dicionário de dados com as variáveis utilizadas na análise.	6
2	Exemplo da transformação dos dados para o Cliente ID 46251, ilustrando o cálculo da duração e do evento, incluindo a censura na última observação.	7
3	Resumo das estatísticas descritivas das variáveis numéricas.	10
4	Resumo do resultado do Modelo de Cox.	16

1 INTRODUÇÃO

A análise de comportamento de compra dos consumidores em plataformas de e-commerce tem se tornado uma área central de pesquisa devido à crescente competitividade no mercado digital e à importância de entender as preferências dos clientes para melhorar a experiência de compra e maximizar a rentabilidade. O comportamento do cliente online, especialmente no que diz respeito ao tempo e à frequência com que ele realiza compras, pode fornecer insights valiosos sobre a sua lealdade e intenção de compra. No entanto, prever com precisão quando um cliente fará uma compra ou quando ele se tornará inativo representa um desafio significativo para os profissionais da estatística.

A questão central deste estudo é como modelar o tempo até a próxima compra com base no comportamento ou características do cliente, utilizando dados de um conjunto e-commerce. Além disso, como pode ser previsto a probabilidade de um cliente não comprar novamente (abandono) dentro de um intervalo de tempo é outra questão interessante. Esses questionamentos são relevantes pois suas respostas podem contribuir para o entendimento da dinâmica de compra, prever a rotatividade de clientes e otimizar a alocação de recursos de marketing.

2 JUSTIFICATIVA

A abordagem do problema de prever o comportamento de compra dos consumidores em e-commerce se justifica pela crescente importância de compreender as dinâmicas de consumo no contexto digital. A capacidade de prever quando um cliente realizará uma nova compra ou quando pode abandonar a plataforma permite que as empresas ajustem suas estratégias de marketing de forma mais eficiente, direcionando campanhas personalizadas, otimizando o estoque e melhorando a experiência do cliente.

A utilização da análise de sobrevivência é particularmente adequada para esse tipo de estudo, pois permite modelar o tempo até a ocorrência de um evento específico, como a realização de uma compra ou o abandono de um cliente. Essa abordagem leva em consideração a censura, ou seja, a situação em que o evento de interesse não ocorre dentro do período de observação, fornecendo uma metodologia robusta para a previsão de comportamentos de compra e uma compreensão mais aprofundada dos fatores que influenciam a lealdade e a rotatividade dos clientes.

3 OBJETIVOS

O objetivo principal deste estudo é desenvolver um modelo preditivo utilizando técnicas de análise de sobrevivência para prever o comportamento de compra dos clientes em um ambiente de e-commerce, a fim de fornecer insights valiosos para otimização de estratégias de marketing e aumento da retenção de clientes.

3.1 OBJETIVOS ESPECÍFICOS

- Obter e preparar os dados do conjunto *E-commerce Customer Behavior and Purchase Dataset*;
- Realizar o pré-processamento dos dados, incluindo a limpeza, transformação e seleção das variáveis relevantes para a análise;

- Aplicar a análise de sobrevivência, utilizando o estimador de Kaplan-Meier e o modelo de Cox, para identificar os fatores que influenciam o comportamento de compra e o tempo até a próxima compra;
- Avaliar a performance dos modelos gerados, utilizando métricas adequadas como o teste Log-Rank e o Índice de Concordância;
- Interpretar os resultados para oferecer recomendações práticas para as empresas de e-commerce.

4 METODOLOGIA

Este estudo emprega a Análise de Sobrevivência para modelar o tempo até a ocorrência de um evento de interesse: a recompra de um cliente. A metodologia abrange desde a preparação dos dados até a aplicação e avaliação de modelos estatísticos, utilizando uma abordagem que combina técnicas não-paramétricas e semi-paramétricas.

4.1 FONTE DE DADOS E FERRAMENTAS

Os dados utilizados provêm do conjunto *E-commerce Customer for Behavior Analysis*, disponibilizado na plataforma Kaggle [?]. Trata-se de um dataset sintético com 250.000 registros, simulando transações de clientes em um ambiente de e-commerce.

4.2 TRATAMENTO DOS DADOS

O conjunto de dados utilizado contém 250.000 registros, representando transações de compra, e é composto por 13 variáveis iniciais.

Toda a análise foi conduzida na linguagem de programação Python [?]. Para a manipulação e o pré-processamento dos dados, foi utilizada a biblioteca *pandas* [?]. As visualizações gráficas foram geradas com o auxílio das bibliotecas *matplotlib* e *seaborn*. A modelagem de sobrevivência foi implementada utilizando a biblioteca especializada *lifelines* [?].

4.3 PRÉ-PROCESSAMENTO E TRATAMENTO DOS DADOS

A primeira etapa da análise consistiu na exploração e preparação do conjunto de dados. A Tabela 1 apresenta as variáveis originais e suas respectivas descrições.

Fonte: Elaborado pelo autor (2025).

O primeiro passo consistiu na preparação dos dados para a análise. A coluna **Purchase Date**, que estava em formato de texto (*object*), foi convertida para o tipo **datetime**, permitindo a manipulação de datas e a ordenação cronológica das transações.

Durante a inspeção inicial, observou-se que as colunas **Customer Age** e **Age** eram idênticas, indicando uma redundância. Para evitar multicolinearidade e simplificar o modelo, a coluna **Customer Age** foi removida.

Um ponto de atenção foi a coluna **Returns**, que indica se uma compra foi devolvida (1) ou não (0). Esta variável possuía um volume significativo de valores ausentes, correspondendo a 19% do total de registros. A Figura 1 ilustra a distribuição dos valores, incluindo os ausentes (NaN).

Fonte: Elaborado pelo autor (2025).

TAB. 1: Dicionário de dados com as variáveis utilizadas na análise.

Nome da Coluna	Descrição
Customer ID	Identificador numérico único para cada cliente.
Purchase Date	Data e hora exatas em que a transação foi realizada.
Product Category	Categoria do produto comprado (ex: 'Electronics').
Product Price	Preço de uma única unidade do produto.
Quantity	Número de unidades do produto compradas.
Total Purchase Amount	Valor total da transação (valor do "carrinho").
Payment Method	Método de pagamento utilizado (ex: 'Credit Card').
Returns	Indica se a compra foi devolvida (1) ou não (0).
Age	Idade do cliente.
Gender	Gênero do cliente (ex: 'Male', 'Female').
Churn	Indica se o cliente abandonou a plataforma (1) ou não (0).




FIG. 1: Distribuição dos valores da coluna **Returns** antes do tratamento dos dados ausentes.

Para o tratamento dos dados faltantes, trabalhou-se com a premissa de que a ausência de um registro de devolução implica que a devolução não ocorreu. Esta é uma abordagem comum quando a documentação do processo de registro de dados não está disponível. Portanto, os valores nulos foram substituídos por 0 (não houve devolução). Após a substituição, a distribuição da variável foi alterada, como pode ser visto na Figura 2.

Fonte: Elaborado pelo autor (2025).

4.4 ENGENHARIA DE ATRIBUTOS PARA SOBREVIVÊNCIA

Para aplicar os modelos de sobrevivência, o dataset transacional foi convertido para um formato onde cada linha representa o intervalo entre duas compras consecutivas de um mesmo cliente. Para isso, foram criadas duas variáveis essenciais:

- **duracao:** Representa o tempo (em dias) até o evento. Foi calculada como a diferença entre a data da compra atual e a data da compra seguinte do mesmo cliente.




FIG. 2: Distribuição dos valores da coluna **Returns** após a substituição de valores nulos por 0.

- **evento:** Uma variável binária indicando a ocorrência do evento de interesse (recompra). Assume o valor 1 se houve uma compra subsequente e 0 caso contrário.

Um aspecto fundamental na análise de sobrevivência é o tratamento da **censura**. Neste estudo, as últimas compras de cada cliente são consideradas dados censurados à direita, pois o evento (recompra) não foi observado até o final do período de estudo. Para esses casos, a **duracao** foi calculada como o intervalo entre a data da última compra e a data final do estudo (a data mais recente em todo o dataset), e o **evento** foi definido como 0. A Tabela 2 ilustra este processo.

TAB. 2: Exemplo da transformação dos dados para o Cliente ID 46251, ilustrando o cálculo da duração e do evento, incluindo a censura na última observação.

Customer ID	Purchase Date	proxima_compra	evento	duracao
46251	2020-09-08	2020-11-12	1	65
46251	2020-11-12	2022-03-05	1	477
46251	2022-03-05	2022-05-23	1	79
46251	2022-05-23	2023-09-15	0	479

Fonte: Elaborado pelo autor (2025).

4.5 MODELAGEM ESTATÍSTICA

A modelagem estatística foi dividida em duas abordagens complementares: não-paramétrica, para uma análise exploratória robusta das curvas de sobrevivência, e semi-paramétrica, para investigar o efeito de múltiplas covariáveis simultaneamente.

4.5.1 MÉTODOS NÃO-PARAMÉTRICOS

A abordagem não-paramétrica é fundamental por não impor suposições sobre a distribuição de probabilidade subjacente dos tempos de sobrevivência.

ESTIMADOR DE KAPLAN-MEIER A primeira técnica utilizada foi o **Estimador de Kaplan-Meier** [?], um método para estimar a função de sobrevivência, $S(t)$, a partir de dados que podem ser censurados. A função de sobrevivência representa a probabilidade de um indivíduo (neste caso, o intervalo entre compras de um cliente) "sobreviver" além de um determinado tempo t .

O estimador é calculado pela fórmula do produto-limite:

$$\hat{S}(t) = \prod_{i:t_i \leq t} \left(1 - \frac{d_i}{n_i}\right) \quad (1)$$

Onde:

- t_i são os tempos distintos em que pelo menos um evento (recompra) ocorreu.
- d_i é o número de eventos que ocorreram no tempo t_i .
- n_i é o número de indivíduos em risco (clientes cujos intervalos de compra ainda não terminaram ou não foram censurados) imediatamente antes do tempo t_i .

O resultado é uma curva em degraus, que decresce a cada ocorrência de um evento. A magnitude da queda em cada degrau reflete o risco de evento naquele ponto, condicionado ao número de indivíduos ainda sob observação.

TESTE LOG-RANK Para comparar as curvas de sobrevivência entre dois ou mais grupos (ex: gênero, categoria de produto), foi utilizado o **teste Log-Rank** [?]. Trata-se de um teste de hipóteses não-paramétrico cuja hipótese nula (H_0) é que não há diferença entre as funções de sobrevivência dos grupos. A hipótese alternativa (H_1) é que pelo menos uma das curvas é diferente das demais.

O teste funciona comparando, em cada tempo de evento t_i , o número de eventos observados em cada grupo (O_{ij}) com o número de eventos que seriam esperados (E_{ij}) se a hipótese nula fosse verdadeira. A estatística do teste é calculada somando as diferenças entre observados e esperados ao longo de todos os tempos de evento, e o resultado segue aproximadamente uma distribuição Qui-quadrado (χ^2) com $k - 1$ graus de liberdade, onde k é o número de grupos sendo comparados. A significância é então avaliada a partir do p-valor.

4.5.2 MÉTODOS SEMI-PARAMÉTRICOS

MODELO DE RISCOS PROPORCIONAIS DE COX Para avaliar o efeito simultâneo de múltiplas covariáveis (tanto numéricas quanto categóricas) sobre o tempo de sobrevivência, foi empregado o **Modelo de Riscos Proporcionais de Cox** [?]. Este é um modelo de regressão semi-paramétrico que modela a função de risco (ou taxa de falha), $h(t)$, que representa o risco instantâneo de um evento ocorrer no tempo t , dado que o indivíduo sobreviveu até aquele momento.

A fórmula do modelo de Cox é:

$$h(t|\mathcal{X}) = h_0(t) \exp(\beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p) = h_0(t) \exp(\mathcal{X}\beta) \quad (2)$$

Onde:

- $h(t|\mathcal{X})$ é a função de risco no tempo t para um indivíduo com um vetor de covariáveis $\mathcal{X}$.
- $h_0(t)$ é a função de risco base (*baseline hazard*), que é a parte não-paramétrica do modelo. Ela representa o risco quando todas as covariáveis são zero e não precisa ser especificada para a estimação dos coeficientes.

- $\mathcal{X} = (X_1, X_2, \dots, X_p)$ é o vetor de covariáveis para o indivíduo.
- $\beta = (\beta_1, \beta_2, \dots, \beta_p)$ é o vetor de coeficientes de regressão, estimados a partir dos dados através de máxima verossimilhança parcial.

O resultado principal do modelo é a **Razão de Riscos** (*Hazard Ratio*, HR), calculada como $\exp(\beta_i)$. Um $HR > 1$ para uma covariável indica que um aumento na mesma está associado a um maior risco de ocorrência do evento, enquanto um $HR < 1$ indica um menor risco. O modelo se baseia na premissa de *riscos proporcionais*, que assume que o efeito das covariáveis sobre o risco é constante ao longo do tempo.

4.6 AVALIAÇÃO DOS MODELOS

A validação e comparação dos modelos foram realizadas com métricas apropriadas para cada técnica. Para o teste Log-Rank, a significância estatística foi avaliada com base no p-valor, utilizando um nível de significância de $\alpha = 0.05$.

O desempenho do modelo de Cox foi avaliado utilizando o **Índice de Concordância (C-index)** [?]. Esta métrica avalia a capacidade discriminatória do modelo, sendo análoga à Área Sob a Curva ROC (AUC) em modelos de classificação. O C-index mede a proporção de todos os pares de indivíduos possíveis em que o modelo prediz corretamente a ordem dos seus tempos de sobrevivência. Especificamente, de todos os pares em que um indivíduo teve o evento antes do outro, qual a proporção em que o indivíduo com o menor tempo de sobrevivência previsto de fato teve o evento primeiro. Um valor de 0.5 indica um desempenho aleatório, enquanto 1.0 representa uma predição perfeita.

5 RESULTADOS

5.1 ANÁLISE EXPLORATÓRIA DE DADOS (AED)

Após o pré-processamento e tratamento dos dados, foi realizada uma Análise Exploratória de Dados (AED) para compreender as características da base de clientes e das transações, bem como para investigar relações entre as variáveis.

5.1.1 ESTATÍSTICAS DESCRITIVAS

A análise descritiva das variáveis numéricas do conjunto de dados, apresentada na Tabela 3, revela informações importantes sobre o perfil das transações e dos clientes.

A partir da Tabela 3, destacam-se os seguintes pontos:

- **Base de Clientes:** O dataset acompanha a atividade de 50.000 clientes únicos, que realizaram um total de 250.000 compras, resultando em uma média de 5 compras por cliente.
- **Faixa Etária:** A idade dos clientes varia de 18 a 70 anos. A média e a mediana são muito próximas (aproximadamente 44 anos), indicando uma distribuição simétrica, com o público principal sendo de meia-idade.
- **Preço e Valor da Compra:** Tanto o preço individual dos produtos (**Product Price**) quanto o valor total da compra (**Total Purchase Amount**) apresentam médias e medianas quase idênticas. Isso sugere distribuições de valores bem equilibradas, sem a influência de valores extremos (*outliers*).

TAB. 3: Resumo das estatísticas descritivas das variáveis numéricas.

Estatística	Customer ID	Product Price	Quantity	Total Purchase	Age
Churn					
count	250000.0	250000.0	250000.0	250000.0	250000.0
250000.0					
mean	25004.0	254.7	3.0	2725.4	43.9
0.199					
std	14428.3	141.6	1.4	1442.9	15.4
0.399					
min	1.0	10.0	1.0	100.0	18.0
0.0					
25%	12497.8	132.0	2.0	1477.0	31.0
0.0					
50%	25018.0	255.0	3.0	2724.0	44.0
0.0					
75%	37506.0	377.0	4.0	3974.0	57.0
0.0					
max	50000.0	500.0	5.0	5350.0	70.0
1.0					

- **Taxa de Abandono (Churn):** A média da variável binária Churn é de 0.199, o que informa que aproximadamente 20% das transações no dataset pertencem a clientes que abandonaram a plataforma. Este fato aponta para um desbalanceamento de classes na proporção de 4:1 (não-churn para churn).

5.1.2 DISTRIBUIÇÃO DAS VARIÁVEIS CATEGÓRICAS

A análise das variáveis categóricas, ilustrada na Figura 3, fornece uma visão geral das preferências dos clientes.

Fonte: Elaborado pelo autor (2025).


As principais observações são:

- **Categoria de Produto:** As categorias "Clothing"(Roupas) e "Books"(Livros) são as que possuem maior volume de vendas, com números muito próximos entre si.
- **Método de Pagamento:** O Cartão de Crédito (*Credit Card*) é o método dominante, seguido por PayPal, Dinheiro (*Cash*) e Criptomoeda (*Crypto*).
- **Gênero:** A base de clientes é extremamente equilibrada entre os gêneros Masculino (*Male*) e Feminino (*Female*).

5.1.3 ANÁLISE BIVARIADA VS. CHURN

Para investigar possíveis preditores do abandono de clientes, foi realizada uma análise bivariada entre as variáveis demográficas e de transação com a variável-alvo Churn. Os resultados estão na Figura 4.

Fonte: Elaborado pelo autor (2025).



distribuicao_categoricas.png

FIG. 3: Distribuição das variáveis categóricas: Categoria de Produto, Método de Pagamento, Gênero e Churn.

A análise visual dos gráficos indica que a proporção de churn em relação ao não-churn é visualmente semelhante em todas as categorias de produto, métodos de pagamento e gêneros. Adicionalmente, a distribuição de idade entre os clientes que são churn e os que não são é praticamente idêntica, o que foi confirmado por uma análise numérica detalhada que mostrou medianas e médias de idade iguais para ambos os grupos.

Esta ausência de um sinal claro em preditores simples e estáticos é um resultado crucial. Constatou-se que as variáveis demográficas, bem como as características de compra, não apresentaram, de forma isolada, uma correlação forte com a decisão de um cliente abandonar a plataforma. Esse achado reforça a escolha da Análise de Sobrevida como metodologia central, pois sugere que o comportamento de churn é provavelmente impulsionado por fatores mais dinâmicos e temporais, como a frequência das compras e o tempo entre elas.




FIG. 4: Análise bivariada das variáveis em relação ao Churn.

5.2 ANÁLISE DE SOBREVIVÊNCIA

Nesta seção, são apresentados os resultados obtidos com a aplicação dos modelos de sobrevivência, que visam analisar o tempo até a ocorrência de uma nova compra, utilizando os dados previamente tratados e preparados.

5.2.1 ANÁLISE EXPLORATÓRIA DAS VARIÁVEIS DE SOBREVIVÊNCIA

Antes da modelagem, foi realizada uma análise exploratória para entender como as variáveis de sobrevivência recém-criadas, **evento** e **duracao**, se relacionam com as demais características dos clientes.

A Figura 5 investiga se alguma característica está associada a uma compra ser a última observada para um cliente (**evento** = 0).

Fonte: Elaborado pelo autor (2025).

A análise da Figura 5 mostra que a proporção de **evento**=0 (compra final observada) para **evento**=1 (recompra) é visualmente a mesma em todas as categorias de produto, métodos de pagamento e gêneros. Adicionalmente, a distribuição de idade, representada pelos boxplots, é idêntica para ambos os desfechos. A conclusão é que nenhuma dessas variáveis estáticas parece influenciar a probabilidade de uma compra ser a última registrada de um cliente.




FIG. 5: Análise Bivariada de covariáveis vs. a variável **evento**.

A seguir, a Figura 6 analisa se o tempo até a próxima compra (**duracao**) varia entre diferentes grupos de clientes.

Fonte: Elaborado pelo autor (2025).

A partir dos gráficos de violino, observa-se que a distribuição da duração é praticamente idêntica entre os gêneros, as categorias de produto e os métodos de pagamento. Este é um achado importante, pois sugere que o ciclo de recompra não é influenciado por essas características. Em contrapartida, a distribuição da duração por evento é drasticamente diferente: as durações para recompras (**evento=1**) são, em média, mais curtas, enquanto as durações para dados censurados (**evento=0**) são naturalmente mais longas, o que valida a engenharia de atributos realizada.

5.2.2 ANÁLISE NÃO-PARAMÉTRICA: ESTIMADOR DE KAPLAN-MEIER

A análise inicial foi a estimação da função de sobrevivência geral para toda a base de clientes utilizando o estimador de Kaplan-Meier. A curva resultante, apresentada na Figura 7, mostra a probabilidade de um cliente "sobreviver" (ou seja, não realizar uma nova compra) ao longo do tempo.

Fonte: Elaborado pelo autor (2025).




FIG. 6: Análise Bivariada de covariáveis vs. a variável duracao.




FIG. 7: Curva de Sobrevivência de Clientes (Estimador de Kaplan-Meier).

A curva de Kaplan-Meier revela um declínio acentuado nos primeiros meses, indicando que a probabilidade de um cliente não comprar novamente diminui rapidamente. O principal resultado desta análise é a **mediana do tempo de sobrevivência**, que foi de **187 dias**. Isso significa que 50% dos clientes que realizam uma nova compra o fazem em até 187 dias após a compra anterior.

Para investigar se diferentes grupos de clientes possuíam comportamentos de recompra distintos, as curvas de sobrevivência foram comparadas utilizando o teste Log-Rank. Foram analisados os grupos por Gênero, Volume de Compra e Categoria de Produto. Em todas as comparações, as curvas de sobrevivência dos diferentes grupos se mostraram praticamente idênticas e sobrepostas.

Os resultados dos testes Log-Rank confirmaram a observação visual:

- **Gênero:** O teste não mostrou diferença estatisticamente significativa entre os gêneros masculino e feminino (p-valor = 0.85).
- **Volume de Compra:** Não houve diferença significativa entre os grupos de volume de compra baixo, médio e alto (p-valor = 0.18).
- **Categoria de Produto:** O comportamento de recompra também se mostrou idêntico entre as quatro categorias de produto (p-valor = 0.51).

A análise não-paramétrica concluiu, portanto, que o comportamento de recompra dos clientes neste dataset é notavelmente homogêneo. Fatores como gênero, valor gasto ou categoria do produto não se mostraram, isoladamente, preditores do tempo que um cliente levará para fazer uma nova compra.

5.2.3 ANÁLISE SEMI-PARAMÉTRICA: MODELO DE RISCOS PROPORCIONAIS DE COX

Para avaliar o efeito simultâneo de múltiplas variáveis sobre a probabilidade de recompra, foi ajustado um modelo de Riscos Proporcionais de Cox. O desempenho geral do modelo foi avaliado pelo **Índice de Concordância (C-index)**, cujo valor foi de **0.50**. Um C-index de 0.5 indica que o modelo não possui poder preditivo, sendo equivalente a uma decisão aleatória para prever qual de dois clientes irá recomprar primeiro. Este resultado corrobora os achados da análise não-paramétrica, indicando que as variáveis utilizadas não são bons preditores do tempo de recompra.

A análise dos coeficientes individuais do modelo, detalhada na Tabela 4, reforça essa conclusão.

Fonte: Elaborado pelo autor (2025).

Com exceção da variável **Returns**, todas as outras covariáveis apresentaram p-valores maiores que 0.05, não sendo estatisticamente significativas. A variável **Returns** foi significativa (p=0.01), com uma razão de risco (*hazard ratio*, ou $\exp(\text{coef})$) de 1.01. Isso indica que clientes que devolvem uma compra têm um "risco" de recomprar 1% maior em qualquer ponto no tempo, ou seja, tendem a realizar a próxima compra de forma marginalmente mais rápida. No entanto, o efeito, apesar de estatisticamente significativo, é muito pequeno e não altera a conclusão geral sobre a falta de fortes preditores no modelo.

TAB. 4: Resumo do resultado do Modelo de Cox.

Covariável	coef	exp(coef)	se(coef)	p
Age	0.00	1.00	0.00	0.94
Total Purchase Amount	-0.00	1.00	0.00	> 0.42
Quantity	-0.00	1.00	0.00	> 0.14
Returns	0.01	1.01	0.00	0.01
Gender_Male	-0.00	1.00	0.00	0.85
Product_Category_Clothing	0.00	1.00	0.01	0.78
Product_Category_Electronics	0.01	1.01	0.01	0.24
Product_Category_Home	-0.00	1.00	0.01	0.65
Payment_Method_Credit_Card	-0.01	0.99	0.01	0.08
Payment_Method_Crypto	0.00	1.00	0.01	0.65
Payment_Method_PayPal	-0.01	0.99	0.01	0.15

6 CONCLUSÃO

Este estudo se propôs a desenvolver um modelo preditivo para o comportamento de compra de clientes em e-commerce, com foco em modelar o tempo até a próxima compra utilizando técnicas de análise de sobrevivência. Ao final da investigação, a conclusão mais significativa é a notável homogeneidade no comportamento de recompra dos clientes presentes no dataset.

A Análise Exploratória de Dados (AED) inicial já indicava que variáveis estáticas e demográficas, como gênero e idade, bem como características da transação, como categoria de produto e método de pagamento, não possuíam uma correlação clara ou forte com o abandono (*churn*) dos clientes. Essa ausência de preditores simples foi confirmada e aprofundada pela modelagem de sobrevivência.

A análise não-paramétrica, através do teste Log-Rank, demonstrou que não há diferença estatisticamente significativa nas curvas de sobrevivência ao segmentar os clientes por gênero, volume de compra ou categoria de produto. Diante dessa homogeneidade, a curva de Kaplan-Meier geral (Figura 7) emerge como a ferramenta mais valiosa e prática deste estudo. Ela fornece um modelo robusto do comportamento geral da base de clientes, estabelecendo uma mediana de tempo para a recompra de **187 dias**. Este valor serve como um importante benchmark para a empresa, definindo uma "janela de oportunidade" para ações de reengajamento.

A modelagem semi-paramétrica com o modelo de Riscos Proporcionais de Cox corroborou estes achados. O Índice de Concordância (C-index) de 0.50 indicou que o modelo, com as variáveis disponíveis, não possui poder preditivo superior ao acaso. A análise dos coeficientes reforçou que nenhuma variável teve um impacto estatisticamente significativo no tempo de recompra, com a exceção de um efeito marginal e de pequena magnitude da variável **Returns**.

Respondendo aos objetivos do trabalho, o estudo foi bem-sucedido em modelar o comportamento de compra, e o principal fator identificado foi, paradoxalmente, a ausência de influência das variáveis testadas. A implicação prática deste resultado é que estratégias de marketing e retenção excessivamente segmentadas com base nestes critérios podem não ser eficientes. Em vez disso, uma abordagem mais ampla, baseada no tempo desde a última compra — por exemplo, campanhas direcionadas a todos os clientes que se aproximam da marca de 187 dias — pode gerar um retorno sobre o investimento mais eficaz.

Por fim, é importante reconhecer as limitações do estudo, principalmente o uso de um conjunto de dados sintético, que pode não refletir todas as nuances do comportamento real do consumidor. Trabalhos futuros poderiam se beneficiar da aplicação desta metodologia em dados reais e da inclusão de variáveis mais dinâmicas e comportamentais, como frequência de visitas ao site, tempo de navegação ou interações com campanhas de marketing, que poderiam

revelar padrões não capturados pelas variáveis estáticas aqui analisadas.